


Teoría de la información

En sentido amplio, «información» es todo lo que reduce la incertidumbre. Si se codifica, consituye una serie de «datos» que se pueden comunicar, una operación que adapta la información al procesamiento automático. El dato informático es «digital» (o discreto), y, debidamente codificadas, las señales «analógicas» o continuas se pueden convertir en digitales.

La «teoría de la información», nacida en 1948 gracias a Claude Shannon (en la foto), es una disciplina basada en las matemáticas que estudia los fenómenos relativos a la compresión y transmisión de datos informáticos, directamente derivada de los conceptos de «redundancia» y «entropía».

La redundancia es todo lo que no es absolutamente necesario (pero que habitualmente otorga flexibilidad y fiabilidad), y puede eliminarse mediante la «compresión» (aunque también es posible comprimir datos no redundantes), ya sea con pérdida de información (*lossy*) o sin pérdida (*lossless*). El espacio necesario para el archivo y el volumen de datos que se va a transmitir será inferior al original, lo que ahorra recursos y energía. La entropía define el límite de máxima compresión posible, formalizado por el «primer teorema de Shannon», o «teorema de codificación de fuente». Existe un «segundo teorema de Shannon», o «teorema de la codificación de canal», que indica la máxima eficiencia posible de un método de control y corrección de errores de transmisión debidos al «ruido» (las interferencias) del canal usado, cuya capacidad se conoce.



$$H = - \sum_{i=1}^n p_i \log p_i$$

▲ Se pueden rastrear los principios que subyacen a la teoría de la información en las teorías de las probabilidades y de la estadística. Shannon tendió el «puente» entre información e incertidumbre con su analogía entre información y energía, con la función que define la entropía, la información de una variable aleatoria que indica hasta qué punto se puede comprimir un mensaje. El resultado (H), en términos de «bit de entropía», da el número de bits por palabra para enviar un mensaje.

118888811888881188888118888811888881188888

Cadena de datos original

Cadena de datos comprimida


128512851285128512851285



▲ Los algoritmos de codificación para la compresión de datos tienen como objetivo que los archivos ocupen menos memoria y, al mismo tiempo, menos banda de transmisión durante su envío y recepción. Hay aplicaciones basadas en formatos especiales que llevan a cabo la tarea de compresión y extracción del código: uno de los más conocidos es «zip».

▲ Los algoritmos de compresión *lossless*, sistemas que no conllevan pérdida de información pero que no siempre garantizan una disminución efectiva del número de bits al final del procesamiento, aplican varios expedientes matemáticos, incluso algunos particularmente complejos. En el ejemplo de arriba vemos un sencillo algoritmo (llamado «RLE») que permite comprender de inmediato el mecanismo básico de la compresión: la cadena de caracteres original queda aquí reducida, indicando primero el carácter y luego el número de apariciones consecutivas.


TRANSMISIÓN EN PARALELO




TRANSMISIÓN EN SERIE



◀ Existen dos modalidades distintas de comunicación de datos digitales: en paralelo y en serie. La primera, que permite un flujo de bits garantizado por varios canales, es típica del sistema de conducciones internas del ordenador y asegura una mayor velocidad. La segunda (que incluye el estándar USB) es la más extendida para comunicaciones entre dispositivos y periféricos. Aprovecha el envío secuencial de bits, que, al ser más lento, precisa menos ficheros (menor coste), y está menos sometido a interferencias y errores de transmisión.



▲ Aquí tenemos un típico árbol binario que muestra una «codificación de Huffman», el algoritmo desarrollado en 1952 por David A. Huffman, el más eficiente de los sistemas de asignación de símbolos en cadenas binarias. En el ejemplo, la frase «this is an example of a human tree» está ordenada en base al número de veces que aparece cada carácter, poniendo en parejas de hijos las de menor frecuencia cuyo progenitor esté ordenado como suma de sus hijos. Se podrá descodificar asociando a cada nodo un bit y a las letras valores iguales a 1, 2, 3, 4 o 5 bits según el orden.



◀ El principal método de control de transmisión y memorización de datos es el uso del llamado «bit de paridad», que detecta errores debidos a interferencias de diverso tipo. Se trata de un bit extra añadido al conjunto de bits que se quiere enviar, y que indica si el número de bits con valor de 1 es par o impar. Contando el número de «unos» hallamos el «bit de paridad par», que será 1 si tiene un total impar o 0 si el total de «unos» es par; en el caso de la «paridad impar» sería al contrario: si la suma total de «unos» es par, tendríamos un bit de paridad 1, y si impar, 0. El bit de paridad detecta solo errores impares, y no puede corregirlos. El «código de Hamming», inventado en 1950 por Richard Hamming (1915-1998), utiliza un «código de paridad» distribuido en bits colocados en el orden de las potencias de 2 que, a diferencia del bit de paridad, no solo revela la presencia de un error, sino que localiza el bit equivocado en un determinado conjunto y lo puede corregir con ayuda de otros bits.

Ficheros comprimidos

Los ficheros comprimidos son de distinta naturaleza según las funciones: aparte de los destinados a archivación (ficheros que contienen otros de diferente estructura a su vez comprimidos) como los ZIP, RAR y 7z (7-Zip), que son *lossless* típicos, están los de codificación de imagen, cuyas versiones PNG, GIF y TIFF exigen más memoria pero no suponen pérdida de calidad como los JPEG y GIF con más de 256 colores; están, además, los de codificación de audio, como los famosos MP3 (aún usados, pero anticuados y poco eficientes en muchos aspectos) y FLAC (*lossless*), o los de compresión de vídeo, como MPEG (*lossy*). Obviamente, existen muchos tipos no comprimidos, como el clásico TXT, el más simple de texto, o el PDF, el formato universal de descripción de página que puede ver regulada la propia resolución.

